

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ
ФЕДЕРАЦИИ
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«КУБАНСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ»
(ФГБОУ ВО «КубГУ»)

Факультет компьютерных технологий и прикладной математики
Кафедра вычислительных технологий

ЛАБОРАТОРНАЯ РАБОТА №5.1
Дисциплина: Обработка больших данных

Работу выполнил: _____ Костров А.А.

Направление подготовки: 02.03.02 Фундаментальная информатика и
информационные технологии

Преподаватель: _____ Яхонтов А.А.

Тема. Задача кластеризации.

Цель. Закрепить знания об алгоритмах кластеризации данных, ознакомиться с функциями языка R, осуществляющими кластерный анализ, и принципами их работы. Научиться визуализировать результаты работы функций кластерного анализа и интерпретировать полученные результаты.

1. Подключим библиотеки, загрузим набор данных «Титаник» и выведем фрагмент датасета (рисунок 1).




Рисунок 1

2. Выполним дескриптивный анализ данных (рисунки 2.1-2.2).




Рисунок 2.1




Рисунок 2.2

3. Оценим оптимальное число кластеров с помощью «Метода локтя» (рисунки 3.1-3.2).




Рисунок 3.1




Рисунок 3.2

4. Оценим оптимальное число кластеров с помощью «Метода силуэта» (рисунки 4.1-4.2).




Рисунок 4.1




Рисунок 4.2

5. Оценим оптимальное число кластеров с помощью «Статистики разрыва» (рисунки 5.1-5.2).




Рисунок 5.1




Рисунок 5.2

6. Оценим оптимальное число кластеров с помощью «Алгоритма консенсуса» (рисунки 6.1-6.2).




Рисунок 6.1




Рисунок 6.2

7. Выполним иерархическую кластеризацию набора данных, построив дендрограмму (рисунки 7.1-7.2).




Рисунок 7.1




Рисунок 7.2

8. Построим столбчатые диаграммы для групп (рисунки 8.1-8.3).




Рисунок 8.1




Рисунок 8.2




Рисунок 8.3

9. Построим боксплоты для кластеров (рисунки 9.1-9.2).




Рисунок 9.1




Рисунок 9.2

10. Выполним кластеризацию исходных данных по методу *k*-средних (рисунки 10.1-10.2).




Рисунок 10.1




Рисунок 10.2

11. Выполним построение графика с помощью *pairs* (рисунки 11.1-11.2).




Рисунок 11.1




Рисунок 11.2

12. Построим трёхмерный график *scatterplot3d* (рисунки 12.1-12.2).




Рисунок 12.1




Рисунок 12.2

13. Выведем общую статистику по кластерам (рисунок 13).




Рисунок 13