

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ
ФЕДЕРАЦИИ
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«КУБАНСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ»
(ФГБОУ ВО «КубГУ»)

Факультет компьютерных технологий и прикладной математики
Кафедра вычислительных технологий

ЛАБОРАТОРНАЯ РАБОТА №5.2
Дисциплина: Обработка больших данных

Работу выполнил: _____ Костров А.А.

Направление подготовки: 02.03.02 Фундаментальная информатика и
информационные технологии

Преподаватель: _____ Яхонтов А.А.

Тема. Байесовская классификация и деревья решений на R.

Цель. Научиться выполнять классификацию на основе формулы Байеса и деревьев решений.

1. Подготовим данные для решения задачи классификации. Возьмём датасет, использованный в ходе выполнения предыдущей лабораторной работы, и добавим столбец, содержащий классы, найденные в результате кластерного анализа (рисунок 1).

<

Рисунок 1

2. Разделим данные на две части: обучающую и тестовую выборки — 70% и 30% от исходного датасета соответственно (рисунок 2).

```
classification.R x
Source on Save
5 library(randomForest)
6 library(caret)
7 library(tidyverse)
8
9 df <- read.csv("titanic.csv", stringsAsFactors = TRUE)
10
11 df_model <- df %>%
12   select(cluster, Pclass, Sex, Age, SibSp, Parch, Fare, Embarked) %>%
13   mutate(
14     Age = ifelse(is.na(Age), median(Age, na.rm = TRUE), Age),
15     Embarked = ifelse(is.na(Embarked) | Embarked == "", "S", Embarked),
16     cluster = factor(cluster, levels = c("Бедные", "Средние", "Богатые")),
17     Pclass = factor(Pclass),
18     Sex = factor(Sex),
19     Embarked = factor(Embarked)
20   ) %>%
21   na.omit()
22
23 df_model$Embarked <- droplevels(df_model$Embarked)
24
25 cat("РАЗМЕР ДАННЫХ:", dim(df_model), "\n")
26 print(table(df_model$cluster))
27
28 ind <- sample(2, nrow(df_model), replace = TRUE, prob = c(0.7, 0.3))
29 trainData <- df_model[ind == 1, ]
30 testData <- df_model[ind == 2, ]
31
32 cat("\nTRAIN:", nrow(trainData), " | TEST:", nrow(testData), "\n")
33
```

1:1 (Top Level) ⇅

Console Background Jobs x

R 4.5.2 · ~/Documents/kubsu-files/semester6/big-data/practice/lab5.2_classification/ ↗

```
> setwd("/home/xom9chok37/Documents/kubsu-files/semester6/big-data/practice/lab5.2_classification/")
> source("~/Documents/kubsu-files/semester6/big-data/practice/lab5.2_classification/classification.R")
РАЗМЕР ДАННЫХ: 891 8

Бедные Средние Богатые
  77    644    170

TRAIN: 622 | TEST: 269
```

Рисунок 2

3. Решим задачу классификации с помощью наивного Байесовского классификатора (рисунки 3.1-3.3).

The screenshot shows an RStudio window with a script editor and a console. The script editor contains R code for training and testing a naive Bayes model. The console shows the output of the code, including the training accuracy and confusion matrices for both training and test data.

```

34 cat("\nНАИВНЫЙ БАЙЕС:\n")
35
36 nb_model <- naiveBayes(cluster ~ ., data = trainData)
37
38 nb_train_pred <- predict(nb_model, newdata = trainData)
39 cat("\nМАТРИЦА ОШИБОК НА TRAIN (НАИВНЫЙ БАЙЕС):\n")
40 print(table(Факт = trainData$cluster, Прогноз = nb_train_pred))
41 cat("ТОЧНОСТЬ НА TRAIN:", round(mean(nb_train_pred == trainData$cluster) * 100, 2), "%\n")
42
43 nb_pred <- predict(nb_model, newdata = testData)
44 cat("\nМАТРИЦА ОШИБОК НА TEST (НАИВНЫЙ БАЙЕС):\n")
45 print(confusionMatrix(nb_pred, testData$cluster))
46
47 nb_acc <- mean(nb_pred == testData$cluster)
48 cat("ТОЧНОСТЬ НАИВНОГО БАЙЕСА (TEST):", round(nb_acc * 100, 2), "%\n")
49

```

Console Output:

```

НАИВНЫЙ БАЙЕС:
МАТРИЦА ОШИБОК НА TRAIN (НАИВНЫЙ БАЙЕС):
  Прогноз
Факт Бедные Средние Богатые
Бедные    49      2      0
Средние    0    453      5
Богатые    1      0    112
ТОЧНОСТЬ НА TRAIN: 98.71 %

МАТРИЦА ОШИБОК НА TEST (НАИВНЫЙ БАЙЕС):
Confusion Matrix and Statistics

          Reference
Prediction Бедные Средние Богатые
Бедные      24      0      2
Средние      1    183      0
Богатые      1      3     55

Overall Statistics

          Accuracy : 0.974

```

Рисунок 3.1

classification.R

Source on Save

```

46
47 nb_acc <- mean(nb_pred == testData$cluster)
48 cat("ТОЧНОСТЬ НАИВНОГО БАЙЕСА (TEST):", round(nb_acc * 100, 2), "%\n")
49
50 nb_tables <- nb_model$tables
51
52 par(mfrow = c(2, 2))
53
54 for (var in c("Age", "Fare", "SibSp", "Parch")) {
55   means <- nb_tables[[var]][, 1]
56   sds <- nb_tables[[var]][, 2]
57
58   x_range <- range(df_model[[var]], na.rm = TRUE)
59 }
60
61 (Top Level)

```

Console

Background Jobs

R 4.5.2 · ~/Documents/kubsu-files/semester6/big-data/practice/lab5.2_classification/

Statistics by Class:

	Class: Бедные	Class: Средние	Class: Богатые
Sensitivity	0.92308	0.9839	0.9649
Specificity	0.99177	0.9880	0.9811
Pos Pred Value	0.92308	0.9946	0.9322
Neg Pred Value	0.99177	0.9647	0.9905
Prevalence	0.09665	0.6914	0.2119
Detection Rate	0.08922	0.6803	0.2045
Detection Prevalence	0.09665	0.6840	0.2193
Balanced Accuracy	0.95742	0.9859	0.9730

ТОЧНОСТЬ НАИВНОГО БАЙЕСА (TEST): 97.4 %

ДЕРЕВО РЕШЕНИЙ:

МАТРИЦА ОШИБОК НА TRAIN:

Факт	Прогноз Бедные	Прогноз Средние	Прогноз Богатые
Бедные			
Средние			
Богатые			

Рисунок 3.2




Рисунок 3.3

4. Применим дерево решений (рисунки 4.1-4.3).

classification.R x

Source on Save

```

79 cat("\nДЕРЕВО РЕШЕНИЙ:\n")
80
81 ctree_model <- ctree(cluster ~ ., data = trainData)
82
83 plot(ctree_model, main = "Дерево решений")
84
85 cat("МАТРИЦА ОШИБОК НА TRAIN:\n")
86 print(table(Прогноз = predict(ctree_model), Факт = trainData$cluster))
87
88 ctree_pred <- predict(ctree_model, newdata = testData)
89 cat("\nМАТРИЦА ОШИБОК НА TEST:\n")
90 print(confusionMatrix(ctree_pred, testData$cluster))
91
92 ctree_acc <- mean(ctree_pred == testData$cluster)
93 cat("ТОЧНОСТЬ ДЕРЕВА РЕШЕНИЙ:", round(ctree_acc * 100, 2), "%\n")
94

```

94:1 (Top Level) ↕

Console
Background Jobs x

R 4.5.2 · ~/Documents/kubsu-files/semester6/big-data/practice/lab5.2_classification/

ТОЧНОСТЬ МАШИНСКОГО ОБУЧЕНИЯ (TEST): 77.4 %

ДЕРЕВО РЕШЕНИЙ:

МАТРИЦА ОШИБОК НА TRAIN:

Прогноз \ Факт	Бедные	Средние	Богатые
Бедные	51	0	0
Средние	0	458	0
Богатые	0	0	113

МАТРИЦА ОШИБОК НА TEST:

Confusion Matrix and Statistics

Prediction \ Reference	Бедные	Средние	Богатые
Бедные	26	0	0
Средние	0	186	0
Богатые	0	0	57

Overall Statistics

Accuracy : 1

Рисунок 4.1

classification.R x

Source on Save

```

82
83 plot(ctree_model, main = "Дерево решений")
84
85 cat("МАТРИЦА ОШИБОК НА TRAIN:\n")
86 print(table(Прогноз = predict(ctree_model), Факт = trainData$cluster))
87
88 ctree_pred ← predict(ctree_model, newdata = testData)
89 cat("\nМАТРИЦА ОШИБОК НА TEST:\n")
90 print(confusionMatrix(ctree_pred, testData$cluster))
91
92 ctree_acc ← mean(ctree_pred == testData$cluster)
93 cat("ТОЧНОСТЬ ДЕРЕВА РЕШЕНИЙ:", round(ctree_acc * 100, 2), "%\n")
94

```

94:1 (Top Level)

Console
Background Jobs x

R 4.5.2 · ~/Documents/kubsu-files/semester6/big-data/practice/lab5.2_classification/

Statistics by Class:

	Class: Бедные	Class: Средние	Class: Богатые
Sensitivity	1.00000	1.0000	1.0000
Specificity	1.00000	1.0000	1.0000
Pos Pred Value	1.00000	1.0000	1.0000
Neg Pred Value	1.00000	1.0000	1.0000
Prevalence	0.09665	0.6914	0.2119
Detection Rate	0.09665	0.6914	0.2119
Detection Prevalence	0.09665	0.6914	0.2119
Balanced Accuracy	1.00000	1.0000	1.0000

ТОЧНОСТЬ ДЕРЕВА РЕШЕНИЙ: 100 %

СЛУЧАЙНЫЙ ЛЕС:

Call:

```
randomForest(formula = cluster ~ ., data = trainData, ntree = 200, proximity
```

Рисунок 4.2

Дерево решений





Рисунок 4.3

5. Используем случайный лес (рисунки 5.1-5.3).



The screenshot shows an RStudio window with a script editor and a console. The script editor contains R code for training and testing a random forest model. The console shows the output of the code, including a confusion matrix and overall statistics.

```
classification.R* x
95 cat("\nСЛУЧАЙНЫЙ ЛЕС:\n")
96
97 rf_model ← randomForest(cluster ~ ., data = trainData, ntree = 200,
98                           proximity = TRUE, importance = TRUE)
99
100 print(rf_model)
101
102 rf_pred ← predict(rf_model, newdata = testData)
103 cat("\nМАТРИЦА ОШИБОК НА TEST:\n")
104 print(confusionMatrix(rf_pred, testData$cluster))
105
106 rf_acc ← mean(rf_pred == testData$cluster)
107 cat("ТОЧНОСТЬ СЛУЧАЙНОГО ЛЕСА:". round(rf_acc * 100, 2), "%\n")
108:1 (Top Level) ↕
```

Console **Background Jobs** x

R 4.5.2 · ~/Documents/kubsu-files/semester6/big-data/practice/lab5.2_classification/ ↗

```
      Бедные Средние Богатые class.error
Бедные      50        0         1 0.01960784
Средние      0      458         0 0.00000000
Богатые      0        0      113 0.00000000
```

МАТРИЦА ОШИБОК НА TEST:
Confusion Matrix and Statistics

```
      Reference
Prediction Бедные Средние Богатые
Бедные      25        0         0
Средние      0      186         0
Богатые      1        0        57
```

Overall Statistics

```
Accuracy : 0.9963
```

Рисунок 5.1

Важность признаков в случайном лесу




Рисунок 5.3

6. Приведём итоговую сводку (рисунок 6).




Рисунок 6