

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ
ФЕДЕРАЦИИ
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«КУБАНСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ»
(ФГБОУ ВО «КубГУ»)

Факультет компьютерных технологий и прикладной математики
Кафедра вычислительных технологий

ЛАБОРАТОРНАЯ РАБОТА №6
Дисциплина: Обработка больших данных

Работу выполнил: _____ Костров А.А.

Направление подготовки: 02.03.02 Фундаментальная информатика и
информационные технологии

Преподаватель: _____ Яхонтов А.А.

Тема. Проверка статистических гипотез.

Цель. Ознакомиться с некоторыми статистическими тестами, принципами их работы. Научиться оценивать нормальность распределения выборки, а также выполнять оценку статистических гипотез.

1. Подготовим датасет *athlete_events.csv* и в качестве вида спорта выберем футбол (рисунки 1.1-1.2).

ID	Name	Sex	Age	Height	Weight	Team	NOC	Games	Year	Season	City	Sport	Event	Medal	P
1	1A Dijing	M	24	180	80	China	CHN	1992 Summer	1992 Summer	Barcelona	Basketball	Basketball Men's Basketball	NA		
2	2A Lamusi	M	23	170	60	China	CHN	2012 Summer	2012 Summer	London	Judo	Judo Men's Extra-Lightweight	NA		
3	3 Gunnar Nielsen Aaby	M	24	NA	NA	Denmark	DEN	1920 Summer	1920 Summer	Antwerpen	Football	Football Men's Football	NA		
4	4 Edgar Lindenau Aaby	M	34	NA	NA	Denmark/Sweden	DEN	1900 Summer	1900 Summer	Paris	Tug-Of-War	Tug-Of-War Men's Tug-Of-War	Gold		
5	5 Christine Jacobs Aalio	F	21	185	82	Netherlands	NED	1988 Winter	1988 Winter	Calgary	Speed Skating	Speed Skating Women's 500 metres	NA		
6	5 Christine Jacobs Aalio	F	21	185	82	Netherlands	NED	1988 Winter	1988 Winter	Calgary	Speed Skating	Speed Skating Women's 1,000 metres	NA		
7	5 Christine Jacobs Aalio	F	25	185	82	Netherlands	NED	1992 Winter	1992 Winter	Albertville	Speed Skating	Speed Skating Women's 500 metres	NA		
8	5 Christine Jacobs Aalio	F	25	185	82	Netherlands	NED	1992 Winter	1992 Winter	Albertville	Speed Skating	Speed Skating Women's 1,000 metres	NA		
9	5 Christine Jacobs Aalio	F	27	185	82	Netherlands	NED	1994 Winter	1994 Winter	Lillehammer	Speed Skating	Speed Skating Women's 500 metres	NA		
10	5 Christine Jacobs Aalio	F	27	185	82	Netherlands	NED	1994 Winter	1994 Winter	Lillehammer	Speed Skating	Speed Skating Women's 1,000 metres	NA		
11	5 Christine Jacobs Aalio	F	31	188	75	United States	USA	1992 Winter	1992 Winter	Albertville	Cross Country Skiing	Cross Country Skiing Men's 10 kilometres	NA		
12	6 Per Knut Aaland	M	31	188	75	United States	USA	1992 Winter	1992 Winter	Albertville	Cross Country Skiing	Cross Country Skiing Men's 50 kilometres	NA		
13	6 Per Knut Aaland	M	31	188	75	United States	USA	1992 Winter	1992 Winter	Albertville	Cross Country Skiing	Cross Country Skiing Men's 10/15 kilometres Pursuit	NA		
14	6 Per Knut Aaland	M	31	188	75	United States	USA	1992 Winter	1992 Winter	Albertville	Cross Country Skiing	Cross Country Skiing Men's 4 x 10 kilometres Relay	NA		
15	6 Per Knut Aaland	M	33	188	75	United States	USA	1994 Winter	1994 Winter	Lillehammer	Cross Country Skiing	Cross Country Skiing Men's 10 kilometres	NA		
16	6 Per Knut Aaland	M	33	188	75	United States	USA	1994 Winter	1994 Winter	Lillehammer	Cross Country Skiing	Cross Country Skiing Men's 30 kilometres	NA		
17	6 Per Knut Aaland	M	33	188	75	United States	USA	1994 Winter	1994 Winter	Lillehammer	Cross Country Skiing	Cross Country Skiing Men's 10/15 kilometres Pursuit	NA		
18	6 Per Knut Aaland	M	33	188	75	United States	USA	1994 Winter	1994 Winter	Lillehammer	Cross Country Skiing	Cross Country Skiing Men's 4 x 10 kilometres Relay	NA		
19	6 Per Knut Aaland	M	31	183	72	United States	USA	1992 Winter	1992 Winter	Albertville	Cross Country Skiing	Cross Country Skiing Men's 10 kilometres	NA		
20	7 John Aalberg	M	31	183	72	United States	USA	1992 Winter	1992 Winter	Albertville	Cross Country Skiing	Cross Country Skiing Men's 50 kilometres	NA		
21	7 John Aalberg	M	31	183	72	United States	USA	1992 Winter	1992 Winter	Albertville	Cross Country Skiing	Cross Country Skiing Men's 10/15 kilometres Pursuit	NA		
22	7 John Aalberg	M	31	183	72	United States	USA	1992 Winter	1992 Winter	Albertville	Cross Country Skiing	Cross Country Skiing Men's 4 x 10 kilometres Relay	NA		
23	7 John Aalberg	M	33	183	72	United States	USA	1994 Winter	1994 Winter	Lillehammer	Cross Country Skiing	Cross Country Skiing Men's 10 kilometres	NA		
24	7 John Aalberg	M	33	183	72	United States	USA	1994 Winter	1994 Winter	Lillehammer	Cross Country Skiing	Cross Country Skiing Men's 30 kilometres	NA		
25	7 John Aalberg	M	33	183	72	United States	USA	1994 Winter	1994 Winter	Lillehammer	Cross Country Skiing	Cross Country Skiing Men's 10/15 kilometres Pursuit	NA		
26	7 John Aalberg	M	33	183	72	United States	USA	1994 Winter	1994 Winter	Lillehammer	Cross Country Skiing	Cross Country Skiing Men's 4 x 10 kilometres Relay	NA		
27	7 John Aalberg	M	33	183	72	United States	USA	1994 Winter	1994 Winter	Lillehammer	Cross Country Skiing	Cross Country Skiing Men's 10 kilometres	NA		
28	8 Cornelia "Cor" Aalten (-Strannood)	F	18	168	NA	Netherlands	NED	1932 Summer	1932 Summer	Los Angeles	Athletics	Athletics Women's 100 metres	NA		
29	8 Cornelia "Cor" Aalten (-Strannood)	F	18	168	NA	Netherlands	NED	1932 Summer	1932 Summer	Los Angeles	Athletics	Athletics Women's 4 x 100 metres Relay	NA		
30	9 Antti Sami Aalto	M	26	186	96	Finland	FIN	2002 Winter	2002 Winter	Salt Lake City	Ice Hockey	Ice Hockey Men's Ice Hockey	NA		
31	10 Einar Ferdinand "Einar" Aalto	M	26	NA	NA	Finland	FIN	1952 Summer	1952 Summer	Helsinki	Swimming	Swimming Men's 400 metres Freestyle	NA		
32	11 Jorma Ilmarinen Aalto	M	22	182	76.5	Finland	FIN	1980 Winter	1980 Winter	Lake Placid	Cross Country Skiing	Cross Country Skiing Men's 30 kilometres	NA		
33	12 Jyrki Tapani Aalto	M	31	172	70	Finland	FIN	2000 Summer	2000 Summer	Sydney	Badminton	Badminton Men's Singles	NA		
34	13 Minna Maarit Aalto	F	30	159	55.5	Finland	FIN	1996 Summer	1996 Summer	Atlanta	Sailing	Sailing Women's Windsurfer	NA		
35	13 Minna Maarit Aalto	F	34	159	55.5	Finland	FIN	2000 Summer	2000 Summer	Sydney	Sailing	Sailing Women's Windsurfer	NA		
36	14 Pirkko Hannele Aalto (Mattila-)	F	32	171	65	Finland	FIN	1994 Winter	1994 Winter	Lillehammer	Biathlon	Biathlon Women's 7.5 kilometres Sprint	NA		
37	15 Arvo Ossian Aaltonen	M	22	NA	NA	Finland	FIN	1912 Summer	1912 Summer	Stockholm	Swimming	Swimming Men's 200 metres Breaststroke	NA		
38	15 Arvo Ossian Aaltonen	M	22	NA	NA	Finland	FIN	1912 Summer	1912 Summer	Stockholm	Swimming	Swimming Men's 400 metres Breaststroke	NA		
39	15 Arvo Ossian Aaltonen	M	30	NA	NA	Finland	FIN	1920 Summer	1920 Summer	Antwerpen	Swimming	Swimming Men's 200 metres Breaststroke	Bronze		
40	15 Arvo Ossian Aaltonen	M	30	NA	NA	Finland	FIN	1920 Summer	1920 Summer	Antwerpen	Swimming	Swimming Men's 400 metres Breaststroke	Bronze		
41	15 Arvo Ossian Aaltonen	M	34	NA	NA	Finland	FIN	1924 Summer	1924 Summer	Paris	Swimming	Swimming Men's 200 metres Breaststroke	NA		
42	16 Juhamatti Tapio Aaltonen	M	28	184	85	Finland	FIN	2014 Winter	2014 Winter	Sochi	Ice Hockey	Ice Hockey Men's Ice Hockey	Bronze		
43	17 Paavo Johannes Aaltonen	M	28	175	64	Finland	FIN	1948 Summer	1948 Summer	London	Gymnastics	Gymnastics Men's Individual All-Around	Bronze		

Рисунок 1.1

The screenshot displays the RStudio environment. The top pane shows the source editor with an R script named 'hypothetical.R'. The script contains the following code:

```
35 data_raw <- read.csv("athlete_events.csv",
36                       header = TRUE,
37                       stringsAsFactors = FALSE,
38                       na.strings = c("", "NA", "N/A"),
39                       quote = "\"",
40                       comment.char = "")
41 }
42
43 cat("ПРОВЕРКА СТАТИСТИЧЕСКИХ ГИПОТЕЗ: ВЕС ФУТБОЛИСТОВ И ВЕС БАСКЕТБОЛИСТОВ\n")
44
45 cat("\n\nПОДГОТОВКА ДАННЫХ\n\n")
46 cat(sprintf("Исходное количество записей: %d\n", nrow(data_raw)))
47
48 cat("Столбцы в данных:", paste(names(data_raw), collapse = ", "), "\n")
49
50 if ("Weight" %in% names(data_raw)) {
51   data_raw$Weight <- suppressWarnings(as.numeric(as.character(data_raw$Weight)))
52 } else {
53   stop("Столбец 'Weight' не найден в данных!")
54 }
```

The bottom pane shows the console output, which matches the execution of the script:

```
> source("~/Documents/kubsu-files/semester6/big-data/practice/lab6_hypothetical/hypothetical.R")
ПРОВЕРКА СТАТИСТИЧЕСКИХ ГИПОТЕЗ: ВЕС ФУТБОЛИСТОВ И ВЕС БАСКЕТБОЛИСТОВ


ПОДГОТОВКА ДАННЫХ

Исходное количество записей: 18965
Столбцы в данных: ID, Name, Sex, Age, Height, Weight, Team, NOC, Games, Year, Season, City, Sport, Event, Medal
После удаления NA: 14767
После удаления дубликатов: 10790
Записей по футболу: 472
Записей по баскетболу: 267

Размеры выборки (выступления спортсменов с известным весом):
Футбол — мужчины: 402, женщины: 70
Баскетбол — мужчины: 194, женщины: 73
```

Рисунок 1.2

2. Проведём дескриптивный анализ данных (рисунки 2.1-2.3).



The screenshot shows an RStudio interface with a script editor and a console. The script editor contains R code for a function named `describe` that performs a descriptive analysis of a variable `x`. The console shows the output of the function, which includes summary statistics for two groups: 'Футбол, мужчины' (n = 402) and 'Футбол, женщины' (n = 70). The output is formatted as a table with columns for the statistic, the value, and the unit (kg).

```
hypothetical.R x
Source on Save
Run
Source

113 cat("\n\nДЕСКРИПТИВНЫЙ АНАЛИЗ\n")
114
115 describe <- function(x, name) {
116   if (length(x) == 0 || !is.numeric(x)) {
117     cat(sprintf("\n%s: НЕТ ДАННЫХ\n", name))
118     return(invisible(NULL))
119   }
120
121   x <- x[is.finite(x)]
122
123   if (length(x) == 0) {
124     cat(sprintf("\n%s: НЕТ КОРРЕКТНЫХ ДАННЫХ\n", name))
125     return(invisible(NULL))
126   }
127
128   n <- length(x)
129   m <- mean(x, na.rm = TRUE)
130   med <- median(x, na.rm = TRUE)
131   var <- var(x, na.rm = TRUE)
132   iqr <- IQR(x, na.rm = TRUE)
133   min <- min(x, na.rm = TRUE)
134   max <- max(x, na.rm = TRUE)
135   q1 <- quantile(x, 0.25, na.rm = TRUE)
136   q3 <- quantile(x, 0.75, na.rm = TRUE)
137   asym <- (max - med) / (med - min)
138   exc <- (q3 - med) / (med - q1)
139   out <- list(n = n, m = m, med = med, var = var, iqr = iqr, min = min, max = max, q1 = q1, q3 = q3, asym = asym, exc = exc, out = out)
140   return(out)
141 }
2:15 (Top Level) R Script
```

Console: Background Jobs x

R 4.5.2 · ~/Documents/kubsu-files/semester6/big-data/practice/lab6_hypothetical/

ДЕСКРИПТИВНЫЙ АНАЛИЗ

Футбол, мужчины (n = 402)

Среднее:	72.64 кг	Медиана:	73.00 кг		
Стд.откл:	6.98 кг	Дисперсия:	48.76 кг ²		
Мин:	54 кг	Макс:	95 кг		
Q1:	68.0 кг	Q3:	77.0 кг	IQR:	9.0 кг
Асимметрия:	0.186	Эксцесс:	0.278		
Выбросов (IQR-метод):	5	границы:	[54.5, 90.5] кг		
Значения выбросов:	54, 91, 93, 94, 95				

Футбол, женщины (n = 70)

Среднее:	62.81 кг	Медиана:	62.00 кг		
Стд.откл:	6.50 кг	Дисперсия:	42.21 кг ²		
Мин:	52 кг	Макс:	79 кг		
Q1:	57.2 кг	Q3:	65.0 кг	IQR:	7.8 кг
Асимметрия:	0.565	Эксцесс:	-0.157		
Выбросов (IQR-метод):	2	границы:	[45.6, 76.6] кг		
Значения выбросов:	79, 79				

Рисунок 2.1




Рисунок 2.2




Рисунок 2.3

3. Проведём проверку нормальности и проверку равенства дисперсий (рисунки 3.1-3.3).

The screenshot displays the R Studio environment. The top pane shows the source code for a function named `safe_levene_test` and a call to it. The bottom pane shows the console output of the function.

```

hypothetical.R x
Source on Save
Run Source

278
279 test <- tryCatch(
280   shapiro.test(x),
281   error = function(e) {
282     cat(sprintf("%s: ОШИБКА теста - %s\n", label, e$message))
283     return(NULL)
284   }
285 )
286
287 if (is.null(test)) return(NA)
288
289 cat(sprintf("%s: n = %d, W = %.4f, p-value = %s\n",
290   label, n, test$statistic,
291   format(test$p.value, digits = 4, scientific = TRUE)))
292
293 if (test$p.value > alpha) {
294   cat("    Распределение можно считать нормальным (p > 0.05).\n\n")
295 }
367:49 safe_levene_test(x1, x2, label1, label2, group_name)
R Script

Console Background Jobs x
R 4.5.2 · ~/Documents/kubsu-files/semester6/big-data/practice/lab6_hypothetical/

ПРОВЕРКА НОРМАЛЬНОСТИ И РАВЕНСТВА ДИСПЕРСИЙ

Тест Шапиро-Уилка на нормальность:

Футбол, мужчины: n = 402, W = 0.9921, p-value = 3.148e-02
Распределение отличается от нормального (p < 0.05).
H0: при n > 30 полагаемся на ЦПТ для t-теста.

Футбол, женщины: n = 70, W = 0.9511, p-value = 8.242e-03
Распределение отличается от нормального (p < 0.05).
H0: при n > 30 полагаемся на ЦПТ для t-теста.

Баскетбол, мужчины: n = 194, W = 0.9764, p-value = 2.357e-03
Распределение отличается от нормального (p < 0.05).
H0: при n > 30 полагаемся на ЦПТ для t-теста.

Баскетбол, женщины: n = 73, W = 0.9436, p-value = 2.667e-03
Распределение отличается от нормального (p < 0.05).
H0: при n > 30 полагаемся на ЦПТ для t-теста.
  
```

Рисунок 3.1




Рисунок 3.2





Рисунок 3.3

4. Проверим гипотезы о среднем весе спортсменов (рисунки 4.1-4.2).



The screenshot shows an RStudio interface with a script editor and a console. The script editor contains R code for calculating summary statistics and performing a one-sample t-test. The console displays the output of these operations.

```
374
375 cat("\nОДНОВЫБОРОЧНЫЙ КРИТЕРИЙ: СРЕДНИЙ ВЕС ФУТБОЛИСТОВ\n")
376
377 all_weight_mean <- mean(data_unique$Weight, na.rm = TRUE)
378 all_weight_median <- median(data_unique$Weight, na.rm = TRUE)
379 all_weight_sd <- sd(data_unique$Weight, na.rm = TRUE)
380 all_weight_n <- sum(!is.na(data_unique$Weight))
381
382 cat(sprintf("\nЭталонное значение ( $\mu_0$ ) – средний вес ВСЕХ олимпийцев: %.2f кг\n",
383             all_weight_mean))
384 cat(sprintf("(n = %d, SD = %.2f кг, медиана = %.2f кг)\n",
385             all_weight_n, all_weight_sd, all_weight_median))
386
387 one_sample_test <- function(x, mu, label, is_normal, alpha = 0.05) {
388   n <- length(x)
389   x_mean <- mean(x)
390   x_median <- median(x)
391
392   safe_levene_test(x1, x2, label1, label2, group_name)
}
```

Console Output:

```
ОДНОВЫБОРОЧНЫЙ КРИТЕРИЙ: СРЕДНИЙ ВЕС ФУТБОЛИСТОВ

Эталонное значение ( $\mu_0$ ) – средний вес ВСЕХ олимпийцев: 72.30 кг
(n = 10790, SD = 14.62 кг, медиана = 70.25 кг)

Футбол, мужчины
H0:  $\mu$  = 72.3 кг
H1:  $\mu \neq$  72.3 кг
Выборочное среднее: 72.64 кг, медиана: 73.00 кг, n = 402
Метод: одновыборочный t-тест Стьюдента
Статистика = 0.9919, df = 401.0
p-value = 3.219e-01
95% доверительный интервал: [71.96, 73.33] кг
H0 НЕ ОТВЕРГАЕТСЯ: вес не отличается от 72.3 кг

Футбол, женщины
H0:  $\mu$  = 72.3 кг
H1:  $\mu \neq$  72.3 кг
```

Рисунок 4.1

The screenshot shows an RStudio interface with a script editor and a console. The script editor contains R code for a function `one_sample_test` and a call to `safe_levene_test`. The console displays the output of these functions, including p-values, confidence intervals, and hypothesis test results for a one-sample t-test and a Levene test.

```
hypothetical.R x
Source on Save
Run Source
384 cat(sprintf("n = %d, SD = %.2f кг, медиана = %.2f кг\n",
385             all_weight_n, all_weight_sd, all_weight_median))
386
387 one_sample_test <- function(x, mu, label, is_normal, alpha = 0.05) {
388   n <- length(x)
389   x_mean <- mean(x)
390   x_median <- median(x)
391
392   cat(sprintf("\n %s \n", label))
393   cat(sprintf("  H0: μ = %.1f кг\n", mu))
394   cat(sprintf("  H1: μ ≠ %.1f кг\n", mu))
395   cat(sprintf("  Выборочное среднее: %.2f кг, медиана: %.2f кг, n = %d\n",
396             x_mean, x_median, n))
397
398   if (is_normal || n ≥ 30) {
399     cat("  Метод: одновыборочный t-тест Стьюдента\n")
400     test <- t.test(x, mu = mu, conf.int = TRUE)
401   } else {
367:49 safe_levene_test(x1, x2, label1, label2, group_name) R Script
```

Console Background Jobs x

R 4.5.2 · ~/Documents/kubsu-files/semester6/big-data/practice/lab6_hypothetical/

```
p-value = 3.219e-01
95% доверительный интервал: [71.96, 73.33] кг
H0 НЕ ОТВЕРГАЕТСЯ: вес не отличается от 72.3 кг

Футбол, женщины
H0: μ = 72.3 кг
H1: μ ≠ 72.3 кг
Выборочное среднее: 62.81 кг, медиана: 62.00 кг, n = 70
Метод: одновыборочный t-тест Стьюдента
Статистика = -12.2106, df = 69.0
p-value = 6.569e-19
95% доверительный интервал: [61.27, 64.36] кг
H0 ОТВЕРГАЕТСЯ: вес значительно отличается от 72.3 кг
Средний вес НИЖЕ эталона на 9.5 кг

ДВУХВЫБОРОЧНЫЙ КРИТЕРИЙ: ФУТБОЛ И БАСКЕТБОЛ

Футбол (М) и Баскетбол (М)
H0: μ1 = μ2 (средние веса равны)
```

Рисунок 4.2

5. Проверим гипотезы о равенстве среднего веса в двух выборках (рисунки 5.1-5.2).

The screenshot shows an R Studio interface with a script editor and a console. The script defines a function for a two-sample t-test and performs it on two groups: 'Футбол' and 'Баскетбол'.

```

442
443 cat("\nДВУХВЫБОРОЧНЫЙ КРИТЕРИЙ: ФУТБОЛ И БАСКЕТБОЛ\n")
444
445 two_sample_test <- function(x1, x2, label1, label2,
446                             is_normal1, is_normal2, var_equal, alpha = 0.05) {
447   n1 <- length(x1)
448   n2 <- length(x2)
449   mean1 <- mean(x1)
450   mean2 <- mean(x2)
451
452   cat(sprintf("\n%s и %s\n", label1, label2))
453   cat(" H0: μ1 = μ2 (средние веса равны)\n")
454   cat(" H1: μ1 ≠ μ2 (средние веса различаются)\n")
455   cat(sprintf(" %s: среднее = %.2f кг, n = %d\n", label1, mean1, n1))
456   cat(sprintf(" %s: среднее = %.2f кг, n = %d\n", label2, mean2, n2))
457   cat(sprintf(" Разница средних: %.2f кг\n", mean1 - mean2))
458
459   both_normal <- is_normal1 && is_normal2
367:49 safe_levene_test(x1, x2, label1, label2, group_name)

```

The console output shows the results of the test:

```


ДВУХВЫБОРОЧНЫЙ КРИТЕРИЙ: ФУТБОЛ И БАСКЕТБОЛ

Футбол (М) и Баскетбол (М)
H0: μ1 = μ2 (средние веса равны)
H1: μ1 ≠ μ2 (средние веса различаются)
Футбол (М): среднее = 72.64 кг, n = 402
Баскетбол (М): среднее = 90.08 кг, n = 194
Разница средних: -17.44 кг
Метод: t-тест Уэлча (дисперсии не равны)
Статистика = -18.4428, df = 255.3
p-value = 7.374e-49
95% ДИ для разницы: [-19.30, -15.57] кг
Cohen's d = 1.930 (большой)
H0 ОТВЕРГАЕТСЯ: веса статистически значимо РАЗЛИЧАЮТСЯ.
«Баскетбол (М)» тяжелее на 17.4 кг

Футбол (Ж) и Баскетбол (Ж)
H0: μ1 = μ2 (средние веса равны)
H1: μ1 ≠ μ2 (средние веса различаются)

```

Рисунок 5.1



```
hypothetical.R x
Source on Save
Run
Source

459 both_normal <- is_normal1 && is_normal2
460 large_samples <- n1 >= 30 && n2 >= 30
461
462 if ((both_normal || large_samples)) {
463   if (var_equal) {
464     cat(" Метод: t-тест Стьюдента (дисперсии равны)\n")
465     test <- t.test(x1, x2, var.equal = TRUE)
466   } else {
467     cat(" Метод: t-тест Уэлча (дисперсии не равны)\n")
468     test <- t.test(x1, x2, var.equal = FALSE)
469   }
470 } else {
471   cat(" Метод: тест Манна-Уитни (ненормальные распределения)\n")
472   test <- wilcox.test(x1, x2, conf.int = TRUE)
473 }
474
475 cat(sprintf(" Статистика = %.4f", test$statistic))
452:46 two_sample_test(x1, x2, label1, label2, is_normal1, is_normal2, var_equal, alpha) R Script

Console Background Jobs x
R 4.5.2 ~ /Documents/kubsu-files/semester6/big-data/practice/lab6_hypothetical/
95% ДИ для разницы: [-19.30, -15.57] кг
Cohen's d = 1.930 (большой)
H0 ОТВЕРГАЕТСЯ: веса статистически значимо РАЗЛИЧАЮТСЯ.
«Баскетбол (М)» тяжелее на 17.4 кг

Футбол (Ж) и Баскетбол (Ж)
H0:  $\mu_1 = \mu_2$  (средние веса равны)
H1:  $\mu_1 \neq \mu_2$  (средние веса различаются)
Футбол (Ж): среднее = 62.81 кг, n = 70
Баскетбол (Ж): среднее = 73.23 кг, n = 73
Разница средних: -10.42 кг
Метод: t-тест Уэлча (дисперсии не равны)
Статистика = -8.3686, df = 135.5
p-value = 6.361e-14
95% ДИ для разницы: [-12.88, -7.96] кг
Cohen's d = 1.393 (большой)
H0 ОТВЕРГАЕТСЯ: веса статистически значимо РАЗЛИЧАЮТСЯ.
«Баскетбол (Ж)» тяжелее на 10.4 кг
```

Рисунок 5.2

6. Приведём итоговую сводку (рисунок 6).

```
hypothetical.R x
Source on Save
Run
Source
535 if ("Year" %in% names(data_unique) && is.numeric(data_unique$Year)) {
536   years <- data_unique$Year[is.finite(data_unique$Year)]
537   if (length(years) > 0) {
538     cat(sprintf("Период: %d-%d гг. \n" min(years), max(years)))
452:46 two_sample_test(x1, x2, label1, label2, is_normal1, is_normal2, var_equal, alpha) R Script
```

Console Background Jobs x

R · R 4.5.2 · ~/Documents/kubsu-files/semester6/big-data/practice/lab6_hypothetical/

ЗАКЛЮЧЕНИЕ

Характеристика выборки:
Проанализированы данные о 472 выступлениях футболистов
и 267 выступлениях баскетболистов
Период: 1904-2016 гг.
Всего Олимпийских игр в выборке: 49

Проверка нормальности (тест Шапиро-Уилка, $\alpha = 0.05$):
Футбол, мужчины (n=402): нормальное/ЦПТ
Футбол, женщины (n=70): нормальное/ЦПТ
Баскетбол, мужчины (n=194): нормальное/ЦПТ
Баскетбол, женщины (n=73): нормальное/ЦПТ

Проверка равенства дисперсий (тест Левена, $\alpha = 0.05$):
Мужчины: дисперсии РАЗЛИЧАЮТСЯ
Женщины: дисперсии РАЗЛИЧАЮТСЯ

Одновыборочный критерий:
Эталон: 72.30 кг (средний вес всех олимпийцев, n=10790)
Мужчины-футболисты (72.6 кг): H_0 НЕ ОТВЕРГНУТА
Женщины-футболистки (62.8 кг): H_0 ОТВЕРГНУТА

Двухвыборочный критерий:
Мужчины: различия ЗНАЧИМЫ ($p = 7.374e-49$, $d = 1.930$)
Футбол: 72.6 кг, Баскетбол: 90.1 кг
Женщины: различия ЗНАЧИМЫ ($p = 6.361e-14$, $d = 1.393$)
Футбол: 62.8 кг, Баскетбол: 73.2 кг

Уровень значимости $\alpha = 0.05$
Нормальность: тест Шапиро-Уилка + QQ-plot
Гомогенность дисперсий: тест Левена
Одновыборочный тест: t-тест или Уилкоксон
Двухвыборочный тест: t-тест/Уэлч или Манна-Уитни

Рисунок 6